


C: Nogle statistik-relevante søjlefunktioner. Korrelationsfaktor for bedste rette linje.



Søjler	1	2	3	4	5	6	7
Tekst							
Navn	x	y	dx	dy	xx	yy	xy
Enhed							
Udtryk			x-xm	y-ym	dx*dx	dy*dy	dx*dy
0	-2.00	-0.65	-2.483	-3.600	6.164	12.960	8.938
1	-1.55	0.01	-2.033	-2.940	4.132	8.644	5.976
2	-1.16	0.28	-1.643	-2.670	2.699	7.129	4.386
3	-0.62	3.18	-1.103	-1.103	1.216	0.053	-0.254
4	0.21	2.60	-0.273	-0.350	0.074	0.123	0.095
5	0.62	3.00	0.137	0.050	0.019	0.003	0.007
6	1.11	3.50	0.627	0.550	0.393	0.303	0.345
7	1.48	4.17	0.997	1.220	0.995	1.488	1.217
8	1.89	4.50	1.407	1.550	1.980	2.403	2.181
9	2.42	5.64	1.937	2.690	3.753	7.236	5.211
10	2.91	6.22	2.427	3.270	5.892	10.693	7.937

Værdier 1			
	Navn	Udtryk	Værdi
7	n	Number(x)	11
8			
9	xm	Mean(x)	0.4827
10		Sum(x)/n	0.4827
11	ym	Mean(y)	2.95
12		Sum(y)/n	2.95
13			
14	sx	Sdev(x)	1.653
15		sqrt(Sum(xx) / (n-1))	1.653
16	sy	Sdev(y)	2.259
17		sqrt(Sum(yy) / (n-1))	2.259
18	sxy	SumOfProd(dx,dy) / (n-1)	3.604
19		Sum(xy) / (n-1)	3.604
20			
21	a	Slope(x,y)	1.319
22		sxy / (sx*sx)	1.319
23	b	Intercept(x,y)	2.313
24		ym-a*xm	2.313
25	RC	RegCoeff(x,y)	0.9653
26		sxy / (sx*sy)	0.9653

Figur C1: Udskrifter fra MATCa.FPR. Grafen viser de samme $n = 11$ punkter (x_i, y_i) som i kapitel 4's fig. 4.1 og den viser igen den bedste rette linje

$$y = ax + b, \quad (1)$$

denne gang tegnet under hensyntagen til *alle* punkterne.

I *Værdier 1* ser vi en række af de søjlefunktioner, man må anvende, dersom man *selv* vil regne sig frem til bedste rette linjes a og b og til dens *korrelationskoefficient* c (i tabellen *Værdier* kaldet *RC*, der står for *Regression Coefficient*).

Nogle af søjlefunktionerne udregner størrelser der er velkendte fra den statistiske beskrivelse af et *observations-sæt* $x_0, x_1, x_2, \dots$. Dette gælder *middelværdi* og *standardafvigelse*, der som bekendt er defineret ved

$$\mu_x = \frac{1}{n} \sum_i x_i, \quad (2)$$

$$s_x = \sqrt{\frac{1}{n-1} \sum_i (x_i - \mu_x)^2} \quad (3a)$$

$$= \sqrt{\frac{1}{n-1} \sum_i (x_i^2 - \mu_x^2)} \quad (3b)^1$$

Med μ_y og s_y defineret tilsvarende, og med

$$s_{xy} = \frac{1}{n-1} \sum_i (x_i - \mu_x)(y_i - \mu_y) \quad (4a)$$

$$= \frac{1}{n-1} \sum_i (x_i y_i - \mu_x \mu_y), \quad (4b)$$

haves flg udtryk for linjens konstanter

$$a = \frac{s_{xy}}{s_x^2}, \quad b = \mu_y - a\mu_x (\Leftrightarrow \mu_y = a\mu_x + b), \quad c = \frac{s_{xy}}{s_x s_y}. \quad (5)$$

Lad os se lidt nøjere på de i teksten til fig. C1 beskrevne resultater.

¹ Vi har benyttet at

$$\sum_i (x_i - \mu_x)x_i - \sum_i (x_i - \mu_x)\mu_x = \sum_i x_i^2 - n\mu_x^2 = \sum_i (x_i^2 - \mu_x^2)$$

Vi er stiltiende gået ud fra, at de givne punkter ikke ligger på samme lodrette linje (dvs. at s_x ikke er nul). Skulle dette ske, er de lodrette afstande ubestemte, og vi kan hverken definere a , b eller c . Hvis punkterne ligger på samme vandrette linje (dvs. hvis $s_y = 0$) er der ingen problemer med a og b , men korrelationskoefficienten c bliver ubestemt. Denne er altså ikke uden videre et mål for, i hvilken grad punkterne ligger på linje. Vi vender tilbage til dens betydning nedenfor.

Udledning af formlerne for a og b : Disse parametre skal vælges, så fejlkvadrat-summen

$$\varepsilon = \sum_i (ax_i + b - y_i)^2 \quad (6)$$

bliver minimal. Hertil kræves at

$$\frac{\partial \varepsilon}{\partial a} = 2 \sum_i (ax_i + b - y_i)x_i = 0 \quad \text{og} \quad (7)$$

$$\frac{\partial \varepsilon}{\partial b} = 2 \sum_i (ax_i + b - y_i) = 2n(a\mu_x + b - \mu_y) = 0 \quad (8)$$

Sidste ligning giver $b = \mu_y - a\mu_x$ som postuleret i (5). Dette indsættes i (7) og vi får

$$\begin{aligned} 0 &= \sum_i (a(x_i - \mu_x) - (y_i - \mu_y))x_i \\ &= a \sum_i (x_i^2 - \mu_x x_i) - \sum_i (x_i y_i - x_i \mu_y) \\ &= a \sum_i (x_i^2 - \mu_x^2) - \sum_i (x_i y_i - \mu_x \mu_y) \\ &= as_x^2 - s_{xy} \end{aligned} \quad (9)$$

Heraf følger det ønskede udtryk for a .

Uddybning af resultaterne: Med konstanten b fra (5) ser vi at ligningen $y = ax + b$ for bedste rette linje kan skrives som

$$y = ax + (\mu_y - a\mu_x) = a(x - \mu_x) + \mu_y \quad (10)$$

Den går altså gennem punktet (μ_x, μ_y) . Lad os prøve at vurdere fejlkvadratsummens størrelse når den bedste rette linje erstattes af en ret linje $y = a(x - \mu_x) + \mu_y$ gennem (μ_x, μ_y) med en variabel hældning a . Vi får så

$$\begin{aligned} \varepsilon &= \sum_i (a(x_i - \mu_x) - (y_i - \mu_y))^2 \\ &= a^2 s_x^2 + s_y^2 - 2as_{xy} \\ &= s_x^2(a^2 - 2a) + s_y^2 \\ &= s_x^2(a - a)^2 + s_y^2 - a^2 s_x^2 \\ &= s_x^2(a - a)^2 + s_y^2(1 - c^2) \end{aligned} \quad (11)$$

Fejlkvadratets minimale værdi kan altså skrives

$$\varepsilon_{\min} = s_y^2(1 - c^2) \text{ hvor } c = \frac{s_{xy}}{s_x s_y} = \frac{as_x}{s_y} \quad (12)$$

er korrelationskoefficienten. Idet $\varepsilon_{\min}$ ikke kan være negativ, følger det at

$$-1 \leq c \leq +1, \quad (13)$$

hvor et lighedstegn kun kan gælde, når alle punkterne eksakt ligger på linje - det er jo kun i dette tilfælde, at ε kan være nul. Det er iøvrigt let at kontrollere, at hvis y_i er lig $ax_i + b$ for alle i , så fås

$$\mu_y = a\mu_x + b \quad \text{og} \quad c = \frac{s_{xy}}{s_x |a| s_x} = \frac{a}{|a|} = \begin{cases} +1 & \text{hvis } a > 0 \\ -1 & \text{hvis } a < 0 \end{cases} \quad (14)$$

Det sidste resultat følger umiddelbart af det første og reduktionen

$$s_y = \sqrt{\frac{1}{n-1} \sum_i (ax_i + b - a\mu_x - b)^2} = \sqrt{\frac{a^2}{n-1} \sum_i (x_i - \mu_x)^2} = |a|s_x \quad (15)$$

Når korrelationskoefficienten c er tæt på 1, betyder det altså, at punkterne er tæt på at ligge på samme rette linje. Hvordan forstår vi betydningen af et c , der er tæt på nul? Måske kan følgende overvejelse være en hjælp:

Betragtes s_x som et mål for målepunkternes udstrækning henover x -aksen, da angiver as_x hvor meget linjen stiger, og $c = \frac{s_{xy}}{s_x s_y} = \frac{as_x}{s_y}$ er et mål for hvor stor denne stigning er i forhold til spredningen s_y langs y -aksen. Er denne relative stigning meget lille, så udviser punkternes y værdier næsten ingen afhængighed af x - der er ingen korrelation.

Om forskellen på standardafvigelse s og spredning σ .

Antag at observationerne i sættet $x_1, x_2, \dots, x_n$ er tilfældigt fordelt på, lad os sige 5 forskellige værdier $q_1, q_2, \dots, q_5$ således at q_k forekommer med sandsynligheden p_k . Så er middelværdi og spredning som bekendt defineret ved

$$\mu_q = \sum_k q_k p_k \quad \text{og} \quad \sigma_q = \sqrt{\sum_k (q_k - \mu_q)^2 p_k} \quad (16)$$

Lader vi h_k betegne hyppigheden af observationen q_k blandt x -er, så kan tilnærmelsen

$$p_k \simeq \frac{h_k}{n} \quad (17)$$

være dårlig hvis n ikke er ret stor, men den forventes at blive bedre og bedre jo større n bliver. Det samme gælder tilnærmelserne

$$\mu_q \simeq \mu_x \quad \text{og} \quad \sigma_q \simeq s_x \quad (18)$$